

การจำแนกพันธุ์นกด้วยข้อมูลเสียง

Bird Species Classification by Sounds

Github : [6510503522_DeepLearning_project.ipynb](https://github.com/bunyakasit/6510503522_DeepLearning_project.ipynb)

1. วัตถุประสงค์

โครงการนี้มีวัตถุประสงค์เพื่อศึกษาและพัฒนาแบบจำลอง Convolutional Neural Network (CNN) สำหรับการจำแนกพันธุ์นกจากข้อมูลเสียงร้อง โดยการแปลง สัญญาณเสียงดิบให้เป็นภาพ Mel Spectrogram ซึ่งใช้เป็น Input Feature หลัก

การวิจัยจะมุ่งเน้นการปรับแต่งสถาปัตยกรรม CNN เพื่อให้ได้ประสิทธิภาพในการ จำแนกพันธุ์นกอย่างอัตโนมัติที่สามารถช่วยให้นักวิจัยสามารถติดตามและสำรวจความ หลากหลายทางชีวภาพของนกในพื้นที่ได้อย่างรวดเร็วและไม่รบกวนธรรมชาติ การสร้าง แบบจำลองที่มีประสิทธิภาพจะช่วยเติมเต็มความหวังในการอนุรักษ์ธรรมชาติ และเป็นก้าว สำคัญในการใช้เทคโนโลยีเพื่อการศึกษาด้านนิเวศวิทยาอย่างยั่งยืน

2. การใช้ Deep Learning

2.1. ข้อดีในการใช้ Deep Learning

เนื่องจากข้อมูลเสียงมีความซับซ้อนสูงซึ่งมีปัญหารেื่อง Noise จึงมีความ เหนำะสมมากที่จะใช้ Deep Learning ในการจำแนกสายพันธุ์ เพราะโน้มเดลสามารถเรียนรู้ได้ เองระหว่างการฝึกฝน

โดยในงานนี้ Deep Learning จะฝึกฝนด้วยข้อมูลจากภาพ Mel Spectrogram โดยการทำงานนี้ไม่ต้องพึ่งพาการกำหนดคุณลักษณะด้วยตัวผู้สร้างเอง (Manual Feature Engineering) เมื่อนวิธีดังเดิม ทำให้สามารถจับรูปแบบเสียงที่เป็น เอกลักษณ์เฉพาะของนกแต่ละชนิดได้อย่างมีประสิทธิภาพมากกว่า

2.2. เปรียบเทียบกับการแก้ปัญหาอื่นๆ

Features	CNN	Machine Learning แบบดั้งเดิม	Rule based model
การทำงาน	เรียนรู้คุณลักษณะและ จำแนกอัตโนมัติจาก ข้อมูลดิบ [1]	สร้างแบบจำลองจาก คุณลักษณะที่สกัดแล้ว โดยมนุษย์ [2]	ตัดสินใจตาม กฎ IF-THEN ที่ถูกเขียน ขึ้นโดยมนุษย์
ความแม่นยำ	แม่นยำมาก เพราะ จัดการความซับซ้อน และความแปรปรวน ของเสียงในธรรมชาติ ได้ดี [1]	แม่นยำหัวรับปัญหาที่ ไม่ซับซ้อน	ค่อนข้างต่ำ ไม่สามารถ ปรับตัวเข้ากับความ หลากหลายของเสียง ธรรมชาติได้
ความต้องการข้อมูล	มาก	ปานกลาง	ต่ำ

3. สถาปัตยกรรม Convolutional Neural Network

Layer (type)	Output Shape	Param #
Conv2d-1	[-1, 32, 128, 128]	320
ReLU-2	[-1, 32, 128, 128]	0
BatchNorm2d-3	[-1, 32, 128, 128]	64
MaxPool2d-4	[-1, 32, 64, 64]	0
Conv2d-5	[-1, 64, 64, 64]	18,496
ReLU-6	[-1, 64, 64, 64]	0
BatchNorm2d-7	[-1, 64, 64, 64]	128
MaxPool2d-8	[-1, 64, 32, 32]	0
Conv2d-9	[-1, 128, 32, 32]	73,856
ReLU-10	[-1, 128, 32, 32]	0
BatchNorm2d-11	[-1, 128, 32, 32]	256
MaxPool2d-12	[-1, 128, 16, 16]	0
Conv2d-13	[-1, 256, 16, 16]	295,168
ReLU-14	[-1, 256, 16, 16]	0
BatchNorm2d-15	[-1, 256, 16, 16]	512
MaxPool2d-16	[-1, 256, 8, 8]	0
Dropout-17	[-1, 16384]	0
Linear-18	[-1, 512]	8,389,120
ReLU-19	[-1, 512]	0
BatchNorm1d-20	[-1, 512]	1,024
Dropout-21	[-1, 512]	0
Linear-22	[-1, 114]	58,482

โมเดลนี้มี 4 Convolutional ตามด้วย Fully Connected Layer

โดยใน Convolutional layer 1-4 จะประกอบด้วยการสร้างบล็อกของ Convolution → ReLU → Batch Normalization → Max Pooling โดยมีหน้าที่หลักคือการเปลี่ยน Mel Spectrogram ขนาด (1, 128, 128) ให้เป็นเวกเตอร์คุณลักษณะขนาดใหญ่ (Flattened size: 16,384)

ในส่วนของ Fully Connected Layer จะนำเวกเตอร์คุณลักษณะขนาด 16,384 เข้าสู่ชั้น Linear Layer ขนาด 512 ก่อนจะส่งต่อไปยังชั้น Linear Layer สุดท้ายเพื่อจำแนกเป็น NUM_CLASSES (นก 114 พันธุ์)

Activation Functions: ใช้ ReLU ทั้งหมดเพื่อเพิ่ม Non-linearity

BatchNorm: ใช้ BatchNorm หลัง Convolution และ Linear Layer เพื่อช่วยเรื่องความเสถียรของการ train และช่วยให้ train ได้เร็วขึ้น

Dropout: ใช้ใน Fully Connected Layer เพื่อลด Overfitting

4. ชุดข้อมูล

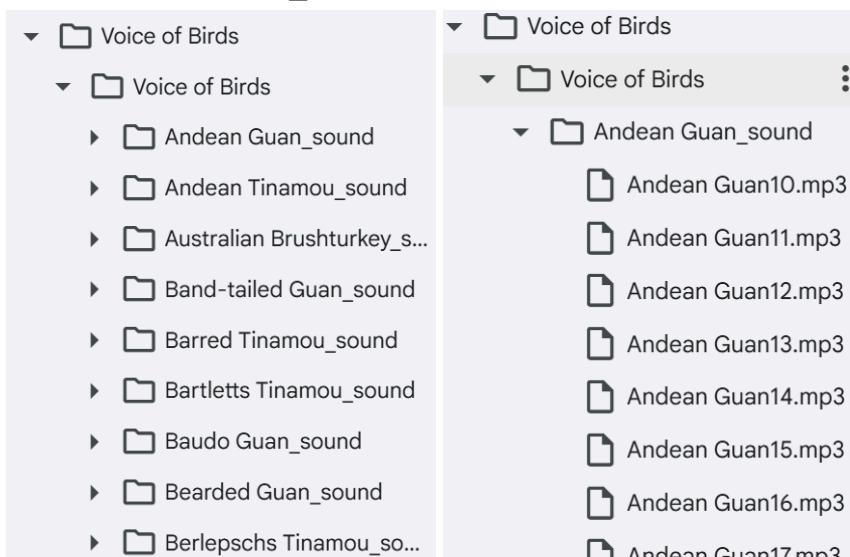
ชุดข้อมูลที่ใช้คือ Sound Of 114 Species Of Birds Till 2022 dataset จาก Kaggle ([LINK : Sound Of 114 Species Of Birds Till 2022 : DATASET \[3\]](#)) ที่เก็บไฟล์เสียงทั้งหมด 2161 ไฟล์ของนกนานาพันธุ์ทั่วโลก 114 พันธุ์ ในชุดข้อมูลมี feature ทั้งหมดดังนี้

- **common_name** - ชื่อโดยทั่วไป
- **scientific_name** - ชื่อวิทยาศาสตร์
- **recordist_name** - ชื่อผู้บันทึก
- **recording_length** - ความยาวของไฟล์เสียง
- **Date** - วันที่บันทึก
- **TYPE** - ประเภทของพฤติกรรมนก
- **xc_id** - ID พิเศษ
- **Time** - เวลาที่บันทึก
- **Country** - ประเทศของเป็นที่อยู่อาศัยของนก
- **Download_link** - ส่วนเชื่อมไปยังไฟล์เสียงนั้นๆ

ตัวอย่าง dataset

	common_name	scientific_name	recordist_name	recording_length	Date	TYPE	xc_id	Time	Country	Download_link
0	Common Ostrich	Struthio camelus australis	Frank Lambert	0:53	2019-10-30	call	XC516153	08:05	South Africa	https://xenocanto.org/516153/download
1	Common Ostrich	Struthio camelus	Jeremy Hegge	0:26	2014-11-20	call	XC208209	04:00	South Africa	https://xenocanto.org/208209/download
2	Common Ostrich	Struthio camelus	Jeremy Hegge	0:04	2014-11-21	call	XC208128	06:00	South Africa	https://xenocanto.org/208128/download
3	Common Ostrich	Struthio camelus	Derek Solomon	0:11	2010-02-09	call	XC46725	07:00	South Africa	https://xenocanto.org/46725/download
4	Common Ostrich	Struthio camelus	Morioka Zoological Park ZOOMO	1:47	2021-09-06	voice during egg laying, zoo collection	XC675445	17:00	Japan	https://xenocanto.org/675445/download

ตัวอย่าง file path ในการเข้าถึงไฟล์เสียงสกุล .mp3 ที่เชื่อมกับ feature common_name และ Download_link



5. ขั้นตอนการทำ

5.1. จัดการชุดข้อมูล

งานหลักของขั้นตอนนี้คือดูรายละเอียดที่ชุดข้อมูลให้มา ทำให้พบว่าชุดข้อมูลมีไฟล์เสียงตามจำนวนตามที่ระบุมาไว้จริง และตรวจเช็คว่าค่า feature ที่ต้องการมี missing value หรือไม่

```
Percentage of Null Values:
common_name          0.000000
scientific_name       0.000000
recordist_name        0.000000
recording_length      0.000000
Date                  0.000000
TYPE                  1.434521
xc_id                 0.000000
Time                  0.000000
Country                0.000000
Download_link         0.000000
```

จะเห็นว่า feature ที่สำคัญคือ “common_name” (ชื่อนก) และ “Download_link” (ลิงค์ที่เชื่อมไปไฟล์เสียง) ไม่มีข้อมูลที่หายไป

จากนั้นจึงตัด feature ที่ไม่จำเป็นออกทั้งหมด และสร้าง feature เสริมชื่อ “label” เป็นการ encoding มาจาก “common_name”

ตัวอย่างการ encoding

```
species_encode = {species: i for i, species in
enumerate(df['common_name'].unique())}
int_to_species = {i: species for species, i in
species_encode.items()}
df['label'] = df['common_name'].map(species_encode)

df.head()
```

ตัวอย่างที่ได้

	common_name	Download_link	label
987	White-bellied Nothura	https://xeno-canto.org/34726/download	50
1189	Collared Brushturkey	https://xeno-canto.org/140728/download	63
129	Grey Tinamou	https://xeno-canto.org/557622/download	13
348	Cinereous Tinamou	https://xeno-canto.org/755297/download	22
355	Cinereous Tinamou	https://xeno-canto.org/683512/download	22

ทำการแบ่งชุดข้อมูลออกเป็น ดังนี้

- train dataset (70%)
- validation dataset (15%)
- test dataset (15%)

โดยก่อนแบ่งข้อมูลทุกครั้งจะทำการตรวจสอบว่ามีชนิดนกไหนที่มีจำนวนตัวอย่างน้อยกว่า 2 ตัวอย่างบ้าง เพื่อป้องกันปัญหาในการแบ่งข้อมูลแบบ stratified split โดยข้อมูลของชนิดนกที่มีตัวอย่างน้อยจะถูกกรองออกไปก่อน

ตัวอย่างโค้ด บางส่วนในการกรองข้อมูลส่วนน้อยออกก่อน split

```
from sklearn.model_selection import train_test_split

# Identify classes with fewer than 2 samples to avoid errors during
stratified split
species_counts_full = df['label'].value_counts()
low_sample_species_full = species_counts_full[species_counts_full <
2].index.tolist()

# Remove rows belonging to low-sample species from the full dataset
df_filtered = df[~df['label'].isin(low_sample_species_full)].copy()
```

5.2. Audio to Mel Spectrogram

ในขั้นตอนนี้คือการ preprocess "ไฟล์เสียงก่อนเข้าฝึกฝนโนมเดล โดยทำการแปลงไฟล์เสียงเป็นรูปภาพ Mel Spectrogram ด้วยไลบรารี **Librosa** เพราะโดยทั่วไปข้อมูลเสียงติบจะไม่ถูกป้อนเข้าสู่โนมเดล deep learning โดยตรง แต่จะถูกแปลงให้อยู่ในรูปแบบของ Spectrogram ก่อน

Spectrogram เป็น "ภาพถ่าย" โดยสรุปของคลื่นเสียง ซึ่งแสดงความถี่ (แกน Y) เทียบกับเวลา (แกน X) และใช้สีเพื่อบุคลิคความเข้มหรือ Amplitude ของแต่ละความถี่

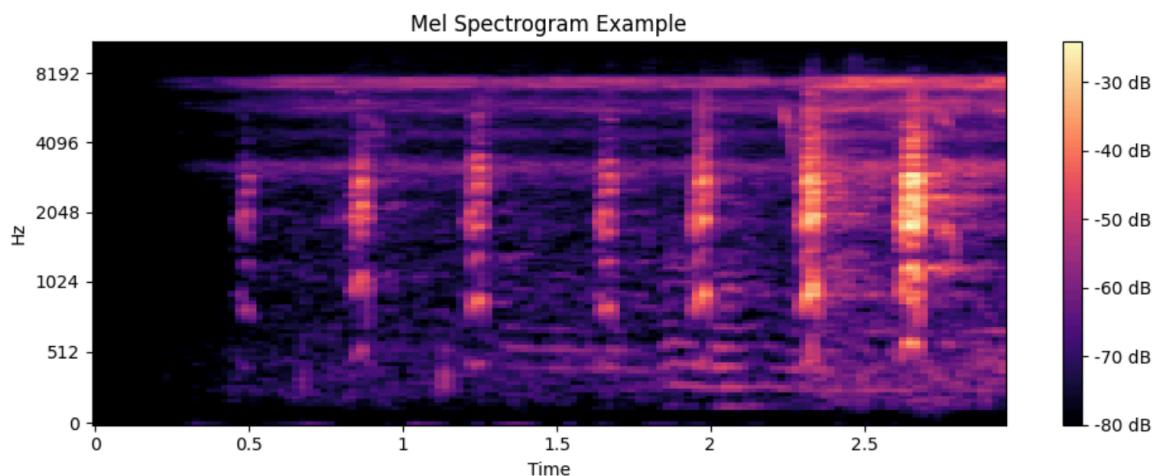
Mel Spectrogram เป็นการปรับปรุงที่สำคัญของ Spectrogram ทั่วไป โดยมีจุดประสงค์เพื่อให้การประมวลผลข้อมูลเสียงเป็นไปในลักษณะที่สอดคล้องกับการรับรู้ของมนุษย์ [4]

ดังนั้น โนมเดล CNN ที่ใช้ Mel Spectrogram จึงสามารถเรียนรู้คุณลักษณะ (features) ที่มีความหมายและสำคัญต่อการแยกแยะเสียงได้ดีขึ้น การใช้ Mel Scale ช่วยให้โนมเดลให้ความสนใจกับความแตกต่างของความถี่ที่มนุษย์อ่อนไหวมากกว่า

ตัวอย่างโค้ด **บางส่วน** ในการแปลง audio

1. Audio → MelSpectrogram	<pre>mel = librosa.feature.melspectrogram(y=audio, sr=self.sample_rate, n_fft=self.n_fft, hop_length=self.hop_length, n_mels=self.n_mels)</pre>
2. Power → Decibel แปลงค่า Mel Spectrogram ที่อยู่ในหน่วยกำลัง (Power) ให้เป็นหน่วย เดซิเบล (dB) ซึ่งเป็นสเกลแบบลอการิทึมที่เลียนแบบการรับรู้ของหูมนุษย์และช่วยปรับปรุงประสิทธิภาพของ CNN	<pre>mel_db = librosa.power_to_db(mel, ref=np.max)</pre>
3. Pad/Trim Time Steps ปรับขนาดมิติของเวลา (T) ของ Mel Spectrogram ให้เป็นค่าคงที่ตามที่กำหนด (TIME_STEPS = 128) โดยการ ตัด (Trim) หรือ เติม (Pad) ด้วยค่าที่ต่ำที่สุด เพื่อให้ทุกตัวอย่างมีขนาดภาพเท่ากัน สำหรับป้อนเข้า CNN	<pre>T = mel_db.shape[1] if T >= self.time_steps: mel_proc = mel_db[:, :self.time_steps] else: pad = self.time_steps - T mel_proc = np.pad(mel_db, ((0, 0), (0, pad)), mode='constant', constant_values=np.min(mel_db))</pre>
4. MelSpectrogram → Tensor แปลง array ของ Mel Spectrogram ที่ผ่านการปรับขนาดแล้ว (mel_proc) ให้เป็น PyTorch Tensor ชนิด float และเพิ่มมิติที่ 0 (unsqueeze(0)) ซึ่งเป็นมิติของ ของ สัญญาณ (Channel) (จาก (128, 128) เป็น (1, 128, 128)) เพื่อให้ตรงตาม Input Format ของ CNN	<pre>mel_tensor = torch.from_numpy(mel_proc).float().unsqueeze(0)</pre>

ตัวอย่าง Heatmap จาก Mel Spectrogram



ตัวอย่าง Tensor ที่จากการแปลง Mel Spectrogram

Shape of Mel Spectrogram batch: torch.Size([32, 1, 128, 128])
Shape of Labels batch: torch.Size([32])

Sample of Mel Spectrogram data (first sample, first channel, first 5x5 pixels):
 [[-80. -80. -80. -80. -80.]
 [-80. -80. -80. -80. -80.]
 [-80. -80. -80. -80. -80.]
 [-80. -80. -80. -80. -80.]
 [-80. -80. -80. -80. -80.]]

5.3. สร้างโมเดล CNN

ลักษณะของสถาปัตยกรรมได้ระบุไว้แล้วในข้อที่ 3

ตัวอย่างโค้ด บางส่วนในการสร้างโมเดล CNN

1. ชั้น Convolutional

ทำหน้าที่สกัด Features ที่สำคัญจากภาพ Mel Spectrogram โดยการใช้ตัวกรอง หลายชั้น เพื่อลดขนาดภาพและเพิ่มความลึกของช่องสัญญาณ (Channels)

```
# 1. Input (1, 128, 128) -> Output (32, 64, 64)
self.layer1 = nn.Sequential(
    nn.Conv2d(1, 32, kernel_size=3,
    stride=1, padding=1),
    nn.ReLU(),
    nn.BatchNorm2d(32),
    nn.MaxPool2d(kernel_size=2,
    stride=2)
)

# 2. Input (32, 64, 64) -> Output (64, 32, 32)
self.layer2 = nn.Sequential(
    nn.Conv2d(32, 64, kernel_size=3,
```

	<pre> stride=1, padding=1), nn.ReLU(), nn.BatchNorm2d(64), nn.MaxPool2d(kernel_size=2, stride=2)) # 3. Input (64, 32, 32) -> Output (128, 16, 16) self.layer3 = nn.Sequential(.) # 4. Input (128, 16, 16) -> Output (256, 8, 8) self.layer4 = nn.Sequential(.) </pre>
2. ขั้น Fully Connected <p>ทำหน้าที่จำแนกประเภท (Classifier) โดยรับคุณลักษณะที่สกัดออกมานแล้ว เพื่อคำนวณความน่าจะเป็นของแต่ละพันธุ์ และให้ผลลัพธ์สุดท้ายเป็น num_classes</p>	<pre> self.fc = nn.Sequential(nn.Dropout(0.5), nn.Linear(self.fc_input_size, 512), nn.ReLU(), nn.BatchNorm1d(512), # ใช้ BatchNorm1d ก่อน Dropout ใน FC Layer nn.Dropout(0.5), nn.Linear(512, num_classes)) </pre>
3. โครงสร้างการไฟลของข้อมูล (Forward Pass) <p>กำหนดทิศทางการไฟลของข้อมูล (Input x) ผ่านชั้นต่างๆของโมเดล ตั้งแต่ Layer 1 ไปจนถึงชั้น Fully Connected</p>	<pre> def forward(self, x): out = self.layer1(x) out = self.layer2(out) out = self.layer3(out) out = self.layer4(out) out = out.reshape(out.size(0), -1) out = self.fc(out) return out </pre>

5.4. การฝึกฝน

การฝึกฝนจะใช้เพียง 20 epochs เพื่อความเหมาะสมของเวลาในการประมวลผล โดยโค้ดตัวอย่างต่อไปนี้แบ่งออกเป็น 3 ส่วนหลักตามลำดับการทำงานในแต่ละ epoch ดังนี้

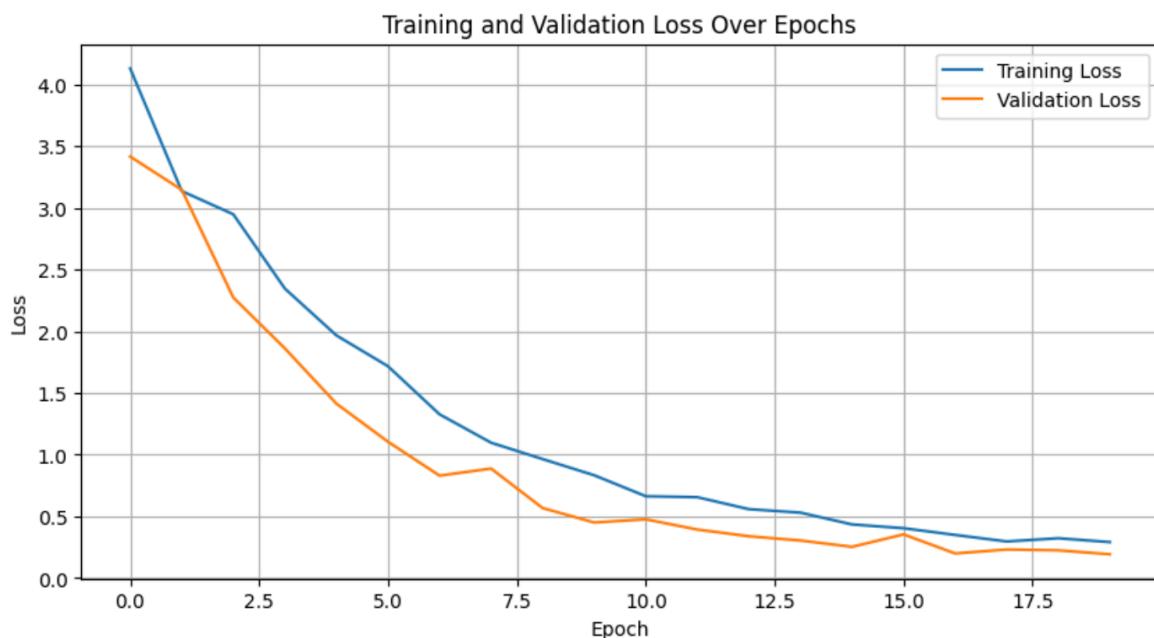
ตัวอย่างโค้ด <u>บางส่วน</u> ในฝึกฝนโมเดล	
1. Training <p>แบ่งเป็น 4 ส่วน</p> <ul style="list-style-type: none"> Forward Pass ป้อน data เข้าสู่โมเดลเพื่อคำนวณ output และค่า Loss Zero Grad ใช้ OPTIMIZER.zero_grad() เพื่อล้างค่า Gradients เก่าก่อนเริ่ม Batch ใหม่ Backward Pass ใช้ loss.backward() เพื่อคำนวณการไดร์ฟบัคซ์ (Gradients) Optimization ใช้ OPTIMIZER.step() เพื่อปรับน้ำหนัก (Weights) ของโมเดลให้ Loss ลดลง 	<pre># Lists สำหรับเก็บค่า Loss และ Accuracy เพื่อวาดกราฟ train_losses = [] val_losses = [] NUM_EPOCHS = 20 # Training Loop for epoch in range(NUM_EPOCHS): # --- Training Phase --- model.train() running_loss = 0.0 running_accuracy = 0.0 # ตัวแปรสำหรับแสดงตัวอย่าง example_printed = False for batch_idx, (data, labels) in enumerate(tqdm(train_loader, desc=f"Epoch {epoch+1} Training")): data = data.to(DEVICE) labels = labels.to(DEVICE) # Forward pass outputs = model(data) loss = CRITERION(outputs, labels) # Backward and optimize OPTIMIZER.zero_grad() loss.backward() OPTIMIZER.step() ... </pre>
2. Validation <ul style="list-style-type: none"> ช่วง Setup 	<pre>model.eval() val_loss = 0.0 val_accuracy = 0.0</pre>

<p>model.eval() มีหน้าที่ตั้งค่าโมเดลเป็นโหมดประเมินผล (หยุดการทำงานของ Dropout และ BatchNorm เพื่อให้ผลลัพธ์คงที่) torch.no_grad() ช่วยปิดการคำนวณ Gradient เพื่อประหยัดหน่วยความจำและเวลา เนื่องจากเราไม่ต้องการปรับน้ำหนักโมเดลในขั้นตอนนี้</p> <ul style="list-style-type: none"> - ช่วง Execution การวัดประสิทธิภาพ: ทำการป้อนข้อมูล Validation (val_loader) เข้าสู่โมเดลเพื่อคำนวณค่า Val Loss และ Val Accuracy ค่าเหล่านี้จะใช้วัดว่าโมเดลที่ถูกฝึกไปแล้ว 	<pre> with torch.no_grad(): for data, labels in val_loader: data = data.to(DEVICE) labels = labels.to(DEVICE) outputs = model(data) loss = CRITERION(outputs, labels) val_loss += loss.item() * data.size(0) val_accuracy += calculate_accuracy(outputs, labels) * data.size(0) ... </pre>
<h3>3. การบันทึกและแสดงผล</h3> <p>คำนวณค่า Loss และ Accuracy เฉลี่ยต่อ Epoch ทั้งชุด Training และ Validation จากนั้นแสดงผลลัพธ์ และเก็บค่าไว้ใน train_losses และ val_losses เพื่อใช้วัดกราฟสรุปในภายหลัง</p>	<pre> epoch_val_loss = val_loss / len(val_dataset) epoch_val_acc = val_accuracy / len(val_dataset) val_losses.append(epoch_val_loss) print(f"Epoch {epoch+1}/{NUM_EPOCHS}: Train Loss: {epoch_train_loss:.4f}, Train Acc: {epoch_train_acc:.4f}, Val Loss: {epoch_val_loss:.4f}, Val Acc: {epoch_val_acc:.4f}\n") </pre>

5.5. การประเมินผล

การประเมินใช้ทั้ง Accuracy, Precision, Recall, F1-score และทำการแสดงกราฟ train loss vs validation loss เพราะการดูหลาย metrics ช่วยให้เราเข้าใจประสิทธิภาพของโมเดลได้รอบด้านมากขึ้นครับ แทนที่จะดูแค่ Accuracy เพียงอย่างเดียว ซึ่งจะเห็นได้ว่าทุกค่ามีค่ามากกว่า 80 % ค่า test loss น้อย (0.2408) และค่า training loss และค่า validation loss ลู่เข้าสู่ 0 บ่งบอกว่าโมเดลมีประสิทธิภาพที่ดีและเรียนรู้ข้อมูลได้ค่อนข้างประสบความสำเร็จ

```
Final Test Loss: 0.2408
--- Evaluation Metrics ---
Accuracy: 95.30
Precision (Macro): 92.95
Recall (Macro): 92.45
F1 Score (Macro): 91.96
```



6. แหล่งอ้างอิง

- [1] <https://www.mmthailand.com/>
- [2] <https://aws.amazon.com/th/compare/the-difference-between-ML-and-DL>
- [3] Sound Of 114 Species Of Birds Till 2022 : DATASET
- [4] Audio Deep Learning Made Simple | Ketan Doshi Blog